

基于大语言模型增强的零样本知识抽取方法

皮乾坤, 卢记仓, 祝涛杰, 彭悦翎

引用本文

皮乾坤, 卢记仓, 祝涛杰, 彭悦翎. [基于大语言模型增强的零样本知识抽取方法](#)[J]. 计算机科学, 2025, 52(11): 22-29.

PI Qiankun, LU Jicang, ZHU Taojie, PENG Yueling. [Zero-shot Knowledge Extraction Method Based on Large Language Model Enhanced](#) [J]. Computer Science, 2025, 52(11): 22-29.

相似文章推荐 (请使用火狐或 IE 浏览器查看文章)

Similar articles recommended (Please use Firefox or IE to view the article)

[基于审判逻辑的裁判文书生成方法](#)

Method for Generating Judgment Documents Based on Trial Logic

计算机科学, 2025, 52(11): 223-229. <https://doi.org/10.11896/jsjcx.250500054>

[Instruct-Malware:基于控制流图的大型语言模型恶意软件分析](#)

Instruct-Malware:Control Flow Graph Based Large Language Model Analysis of Malware

计算机科学, 2025, 52(11): 40-48. <https://doi.org/10.11896/jsjcx.241100118>

[DF-RAG:基于查询重写和知识选择的检索增强生成方法](#)

DF-RAG:A Retrieval-augmented Generation Method Based on Query Rewriting and Knowledge Selection

计算机科学, 2025, 52(11): 30-39. <https://doi.org/10.11896/jsjcx.241000117>

[基于组合上下文提示的大型语言模型领域知识问答研究](#)

Research on Domain Knowledge Question Answering via Large Language Models with Compositional Context Prompting

计算机科学, 2025, 52(11): 13-21. <https://doi.org/10.11896/jsjcx.241200198>

[大语言模型与谣言:生成与检测的综述](#)

Large Language Models and Rumors:A Survey on Generation and Detection

计算机科学, 2025, 52(11): 1-12. <https://doi.org/10.11896/jsjcx.250700034>

基于大语言模型增强的零样本知识抽取方法

皮乾坤 卢记仓 祝涛杰 彭悦翎

信息工程大学数据与目标工程学院 郑州 450001

(piqiankun2000@163.com)

摘要 知识抽取任务旨在从复杂的信息资源中抽取结构化知识。然而,现有的知识抽取研究往往需要依赖大量人工标注数据,这导致了高成本消耗。对此,提出一种基于大语言模型增强的零样本知识抽取方法,旨在不依赖任何人工标注数据,利用大模型强大的语义推理能力,自动化地完成知识抽取任务,降低数据标注成本。具体而言,首先对测试集数据进行格式预处理,并基于此微调跨领域的通用大模型得到数据标注模型,利用该模型对相关文本进行标注,以获得相应的实体及属性推理信息。然后,为这些信息设置新的思维链提示范式,进一步微调特定领域的专业大模型得到知识抽取模型。此外,通过不断增加数据迭代训练,以提升模型性能。最后,利用大模型对测试集的属性信息进行增强,以提高知识抽取模型对文本的理解能力,进而增强知识抽取性能。在多个大模型上的基准测试实验结果进一步证明,提出的零样本知识抽取框架具有更加显著的性能提升。

关键词: 大语言模型;零样本知识抽取;数据标注模型;思维链提示;知识抽取模型

中图分类号 TP391

Zero-shot Knowledge Extraction Method Based on Large Language Model Enhanced

PI Qiankun, LU Jicang, ZHU Taojie and PENG Yueling

School of Data and Target Engineering, Information Engineering University, Zhengzhou 450001, China

Abstract The knowledge extraction task aims to extract structured knowledge from complex information resources. However, existing research on knowledge extraction often relies on a large amount of manually annotated data, leading to high costs. To address this challenge, this paper proposes a zero-shot knowledge extraction method enhanced by large language models, which aims to perform knowledge extraction tasks automatically without relying on any manually annotated data, leveraging the strong semantic reasoning capabilities of large models to reduce data annotation costs. Specifically, it first preprocesses the format of the test set data and fine-tunes a general-purpose large model across domains to obtain a data annotation model. This model is then used to annotate relevant texts to extract corresponding entity and attribute inference information. Next, this paper establishes a new chain of thought prompting paradigm for this information and further fine-tunes a specialized large model for a specific domain to obtain a knowledge extraction model. Additionally, it continuously increases the data and iteratively trains to enhance the model's performance. Finally, it enhances the attribute information of the test set using the large model to improve the knowledge extraction model's understanding of the text, thereby enhancing its extraction performance. Benchmarking experiments on multiple large models further demonstrate that the proposed zero-shot knowledge extraction framework achieves a significant performance improvement.

Keywords Large language model, Zero-shot knowledge extraction, Data annotation model, Chain of thought, Knowledge extraction model

1 引言

随着网络信息量的激增,海量数据的涌入使得人工筛选和信息整理变得极为困难,数据的多样性和复杂性使得传统的数据处理方法逐渐失去效力,无法满足日益增长的数据需求。因此,如何快速有效地从复杂的信息资源中抽取结构化

化的知识,成为知识抽取研究的重点。知识抽取任务的目标是从非结构化或半结构化的文本数据中提取有用的、有价值的信息,并将其转化为结构化的知识存储到知识库中,便于进一步分析与利用^[1]。然而,这项任务极具挑战性,尤其是在面对大量且多样化的信息时,为确保知识抽取的质量,研究人员通常需要制定精细的标注指南,以确保人类注释者严格遵循

到稿日期:2024-10-11 返修日期:2024-12-13

基金项目:河南省自然科学基金(222300420590)

This work was supported by the Natural Science Foundation of Henan Province(222300420590).

通信作者:卢记仓(lujicang@sina.com)

这些指南进行数据标注^[2-3]。

现有的知识抽取相关研究^[4-5]过于依赖监督式或半监督式学习,这种方法限制了模型在缺乏大量人工标注数据场景下的应用。为应对这些挑战,零样本学习(Zero-shot Learning)技术^[6-7]被提出。该方法的核心思想是利用已有知识来推理未知场景或领域下的数据,为解决人工标注数据稀缺问题提供了一种可行性方案,尤其在快速适应新任务场景等实际应用中具有重要价值。

尽管零样本知识抽取研究^[8-10]取得了一定的效果,但这些方法过于依赖人工设计的特征规则,导致其在泛化场景中的表现不佳,从而使得抽取的信息不准确。此外,随着数据量的增加,这些方法可能面临性能瓶颈,难以高效处理大规模数据。大语言模型^[11]的不断发展为零样本知识抽取方法提供了全新的思路,其具备强大的语义理解能力,能够从大量无标注文本中捕捉丰富的上下文信息,这种能力显著提高了零样本学习的效果。因此,为更好地完成零样本知识抽取任务,本文提出一种基于大语言模型增强的零样本知识抽取方法,通过将跨领域通用模型与特定领域专业模型协同合作,实现优势互补,共同完成零样本知识抽取任务。

本文的主要工作贡献总结如下:

- 1)针对未知场景或领域任务中依赖大量人工标注数据所带来的高成本消耗问题,提出了一种新的基于大模型进行自动标注的方法,实现无监督数据与目标数据的对齐,从而更有效地应对零样本任务。
- 2)针对知识抽取任务中泛化场景不佳的问题,提出采用通用模型与专业模型相结合的方式,通用模型提供更广泛的知识背景,专业模型对特定任务进行深度优化,从而增强对领域任务的应对能力。
- 3)在基准测试集上的实验结果进一步证明,本文提出的模型框架相比于基线模型,在两个数据集的零样本知识抽取性能上分别提升了7.13个百分点和8.59个百分点。

2 相关工作

零样本知识抽取旨在没有特定任务标注数据的情况下,通过模型的泛化能力,从未见过的领域文本中抽取出相关

知识。该技术的主要优势在于降低了对标注数据的依赖,使得知识抽取能在数据相对匮乏的情况下进行。

传统的零样本知识抽取方法^[8,10]主要对现有数据特征进行分析,并利用相关辅助信息,如标签的同义词和关键字等,来实现对未标注数据的零样本学习。然而,随着数据量的持续增长,这种方法在处理效率上显示出不足。为更好地解决这一问题,越来越多的研究者开始提出利用大模型丰富的语义表示能力,尤其是在零样本学习场景中展现出的强大迁移学习能力,来更有效地处理零样本知识抽取任务。

最近的研究中,Wang等^[12]将知识抽取任务框定为自然语言描述性指令,并在各种知识抽取任务中训练大模型,以此对未见过的标签的任务进行评估。Sainz等^[13]指出,先前研究中的标签注释指南不够明确,因此提出一种新的方法,通过微调符合特定注释设计规则的数据替代传统的注释模式,以此提高零样本学习在特定领域的性能。随着研究的不断深入,许多研究者开始针对特定领域微调知识抽取大模型,以适应该领域的特定需求。Hu等^[14]开始探讨大模型能否从放射报告中提取有用的信息。通过ChatGPT为知识抽取任务设计相应的提示模板,并将该模板与放射学报告相结合,进一步生成领域适应的提示,最后,将大模型的输出转换为结构化的抽取结果。Kartchner等^[15]探索了使用大模型进行零样本临床实验数据分析的可行性,在对未知标签的任务评估中,训练得到的领域抽取模型具有良好的性能。

尽管上述方法在特定领域零样本知识抽取上取得了一定的效果提升,但它们在面对场景泛化和未知领域的挑战时仍有不足,缺乏在多样化场景下的有效性和适应性。

3 本文方法

本文提出的零样本知识抽取框架如图1所示,该框架主要包括数据标注和知识抽取两部分。首先,在数据标注模块中,对测试集数据进行预处理,并通过微调通用大模型得到一个数据标注模型。然后,在知识抽取模块中,利用数据标注模型对爬取到的文本进行数据标注,重新设置相应的思维链提示引导模型进行知识抽取,并通过不断迭代训练专业大模型,增强模型的知识抽取性能。




图1 零样本知识抽取框架图
Fig. 1 Framework of zero-shot knowledge extraction

3.1 数据标注模块

为实现零样本中的数据标注,本节对测试集数据进行格式预处理,将原本的知识抽取数据格式转换为带有数据标注标签的格式,以此实现在不增加人工标注成本的前提下完成数据标注。其数据标注格式转换的示例如图 2 所示。将测试

```
### Instruction: {instruction: 你是一个图谱实体知识结构化专家。根据输入实体类型(entity type)的schema描述,从文本中抽取相应的实体实例和其属性信息,不存在的属性不输出,属性存在多值就返回列表,并输出为可解析的json格式。
schema: [{entity_type: 艺人, attributes: {国籍: 属于某一个国家的国民或公民的法律资格。职业: 服务社会并作为主要生活来源的工作。出生日期: 出生的具体日期。代表作品: 最能体现人物思想水平和艺术风格的作品。}}]}
### Input: {蔡呈, 1983年出生于湖北省恩施土家族苗族自治州, 土家族, 毕业于中国音乐学院, 词曲唱作人, 音乐剧、歌剧演员, 湖北省民族歌舞团青年男高音歌唱家...}
```

(a) 测试集提示模板示例



预处理

```
### Instruction: {instruction: 你是一个图谱实体知识标注专家。根据input中的内容,从文本中标注相应的实体和属性解释。}
### Input: {蔡呈, 1983年出生于湖北省恩施土家族苗族自治州, 土家族, 毕业于中国音乐学院, 词曲唱作人, 音乐剧、歌剧演员, 湖北省民族歌舞团青年男高音歌唱家...}
### Output: [{entity_type: 艺人, attributes: {国籍: 属于某一个国家的国民或公民的法律资格。职业: 服务社会并作为主要生活来源的工作。出生日期: 出生的具体日期。代表作品: 最能体现人物思想水平和艺术风格的作品。}}]}
```

(b) 数据标注提示模板示例

图 2 数据标注任务预处理

Fig. 2 Data annotation task preprocessing

在进行数据标注模型的微调时,最大化模型的通用推理能力,以识别文本中的实体并解释这些实体所对应的属性信息。通用大模型 LLAMA3-8B 具备丰富的语言理解和生成能力,并在不同任务上表现出优异的性能,相较于专业的知识抽取模型,具备更广泛的知识背景。本文综合考量模型性能与成本之间的平衡,将 LLAMA3-8B 模型作为数据标注任务微调的基线模型。用预处理后的测试集数据微调该模型,使其不断学习如何构造标签数据,增强对无标签文本进行数据标注的能力。

为了降低数据微调大模型的成本,克服特定领域知识抽取任务中信息资源的限制,并确保大模型生成标准化的知识抽取结果,本文采用参数高效微调(PEFT)技术^[16]。通过这种方法,能在资源有限的情况下,最小化微调参数的数量和计算复杂度,从而实现高效和有针对性的模型微调。因此,本文采用 PEFT 技术中的 LORA 微调方法,将图 2 预处理测试集得到的数据作为训练数据,该训练数据涵盖了多个不同领域内的混合数据,包含了广泛的主体和术语,将这些数据用于微调 LLAMA3-8B 模型,能够帮助模型学习到不同领域的特定知识,同时保持对通用问题的理解,最终得到一个具有一定领域知识的通用数据标注大模型。

3.2 知识抽取模块

为使得模型更好地理解 and 适应测试集中的文本数据类型,本节采用测试集中的实体类型作为关键词,这些关键词通常代表相关的实体类型,例如人名、地名、组织机构以及其他特定名词等。然后,以 InstructIE^[17] 和 IEPile^[18] 两个公开的抽取数据集作为数据源,从两个数据集中爬取与关键词相匹配的无标注文本数据,将其作为测试集的无监督数据。

总体而言,知识抽取模块分为标注扩增、知识抽取模型微调和属性增强 3 个部分。首先,通过 3.1 节中得到的数据标注大模型对无标注的文本进行数据标注。然后,将得到的标注数据处理为测试集格式,并基于此微调得到知识抽取模型。最后,采用大模型对测试集中存在的属性

集数据 Instruction 标签中的 Schema 信息修改为 Output,将其作为数据标注任务的输出。为使模型进一步适应数据标注任务,本文采用如下提示模板:“你是一个图谱实体知识标注专家。根据 input 中的内容,从文本中标注相应的实体和属性解释”。完整的数据标注提示范式示例如图 2(b)所示。

缺失问题进行属性解释增强。

具体而言,第一部分主要是将获取到的无标注文本通过数据标注模型实现标注扩增。首先,采取图 2(b)中的提示构造,对 Input 中的输入文本执行 Instruction 中的提示,进而获取到每一段输入文本的实体类型 entity_type 和该实体所具有的属性和解释信息 attributes。然后,为保证生成的标注数据与测试集任务对齐,需要对标注数据进行格式改造。具体地,为该任务设置的思维链提示模板如图 3 所示,将知识抽取问题拆分为两个子问题,进一步指导模型第一步解决抽取实体实例问题,第二步再解决抽取属性实例问题。这种拆分针对性地将复杂的问题简单化,有助于减少大模型在推理过程中涌现的幻觉问题。

```
### Instruction: {instruction: 你是一个图谱实体知识结构化专家。请根据给定的实体类型和属性的schema描述,为了解决“从文本中抽取相应的实体实例和其属性信息”这个问题,我们首先要解决的问题是抽取实体实例,然后抽取属性实例。
schema: [{entity_type: 艺人, attributes: {国籍: 属于某一个国家的国民或公民的法律资格。职业: 服务社会并作为主要生活来源的工作。出生日期: 出生的具体日期。代表作品: 最能体现人物思想水平和艺术风格的作品。}}]}
### Input: {蔡呈, 1983年出生于湖北省恩施土家族苗族自治州, 土家族, 毕业于中国音乐学院, 词曲唱作人, 音乐剧、歌剧演员, 湖北省民族歌舞团青年男高音歌唱家...}
### Output: {艺人: {蔡呈: {国籍: 中国, 职业: [词曲唱作人, 音乐剧、歌剧演员, 湖北省民族歌舞团青年男高音歌唱家], 出生日期: 1983年, 代表作品: 音乐剧黄四姐}}}}
```

图 3 知识抽取提示模板示例

Fig. 3 Example of knowledge extraction prompt template

第二部分主要是知识抽取模型的微调。为进一步提高知识抽取任务的性能,选取专业领域的知识抽取模型作为基线模型进行微调。由于 OneKE 模型^[19]在领域特定的知识抽取方面表现出色,在该基线模型基础上进行微调能更好地适应实际知识抽取任务中的数据特征和需求。因此,本文在该模型上进行 LORA 微调后得到一个专业的知识抽取模型。通过不断迭代图 1 中的知识抽取任务过程,逐步增加训练数据

并重新训练模型,采用相同的训练方法不断优化知识抽取模型,以尽可能达到其最佳性能。

第三部分主要是利用大模型对属性解释进行增强。通过分析测试集发现,许多属性信息的解释不够清晰,存在歧义。为更好地对属性信息加以解释,利用大模型对属性信息进行

了修正。为避免误导原始属性中正确的信息,本文仅对属性解释与属性名相同的信息进行大模型修正,从而在保证不误导正确信息的前提下,提高属性信息的解释性。具体的大模型增强属性信息解释示例如图 4 所示。利用知识抽取模型对属性增强后的测试集进行推理,得到结构化的知识抽取结果。




图 4 大模型实现属性信息增强示例

Fig. 4 Example of attribute information enhanced for large language model

4 实验结果

4.1 数据集

该任务是零样本任务,且数据集¹⁾分为初赛测试集和复赛测试集,两个数据集中的数据类型不同,且实体类型分布也不同,因此能更好地验证模型的泛化能力。初赛测试集包含 1000 条数据,复赛测试集包含 1 024 条数据。每条样本数据包括 3 个字段:id,instruction 和 output。instruction 字段是模型的输入指令,输入指令包括两部分内容:一是需要处理的文本(input),二是定义了输出结构和内容要求的抽取指令(instruction)。output 字段是一个结构化的结果,根据抽取指令中提出的格式要求生成标注答案。示例数据如表 1 所列。

表 1 测试集样本数据示例

Table 1 Example of test set sample data

字段	示例
id	28542
instruction	{instruction:你是一个图谱实体知识结构化专家。根据输入实体类型(entity_type)的 schema 描述,从文本中抽取出相应的实体实例和其属性信息,不存在的属性不输出,属性存在多值就返回列表,并输出为可解析的 json 格式。schema:[{entity_type:足球运动员,attributes:{场上位置:地位或角色。惯用脚:靠习惯使用的脚来完成任务或活动的动作。出生地:人物出生的具体地点。}},input:霍尔岑拜因,194 年 3 月 9 日出生于德国法兰克福,场上司职前锋,曾效力于法兰克福、克鲁塞罗足球俱乐部。}
output	{足球运动员:{霍尔岑拜因:{场上位置:前锋,出生地:德国法兰克福}}}

通过 3.1 节的数据标注模型对无监督数据进行标注,将标注后的数据作为训练集。将训练集和测试集从实体类型的类别数量、平均每条样本数据包含句子的数量和平均每条样

本数据包含的属性解释数量 3 个维度进行统计分析,如表 2 所列。

表 2 训练集和测试集统计分析

Table 2 Statistical analysis of training set and test set

	训练集	测试集
实体类型的类别数量	36	131
平均每条样本数据包含句子的数量	2.9	2.5
平均每条样本数据包含的属性解释数量	9.4	7.6

InstructIE^[17]:该数据集是一个包含超过 30 万条指令的中英文双语的指令数据集,是专门为信息抽取和知识图谱构建任务设计的高质量指令数据集。

IEPile^[18]:该数据集包含约 200 万条指令样本,涵盖了通用、医学、金融等多个领域,并包含了命名实体识别(NER)、关系抽取(RE)、事件抽取(EE)三大核心子任务。

4.2 实验设置

4.2.1 基线模型

在评估模型有效性的实验中,分别选取不同规模和版本的大语言模型作为基准模型,包括 OneKE^[19], llama2-13B-chat^[20], llama3-8B^[21], ChatGLM3-6B^[22], Baichuan2-13B-chat^[23] 和 KnowLM-13B-IE^[24]。

OneKE:基于 Chinese-Alpaca-2-13B 模型全参数微调的版本,是一个专用于信息抽取领域的专业模型。

llama2-13B-chat:Meta 于 2022 年发布的一种开放且高效的大型基础语言模型。针对聊天场景进行了优化,使其在对话生成和理解方面具有更高的效率和准确性。

llama3-8B:Meta 发布的 llama3 系列中的一款轻量级大语言模型,尽管其参数规模较小,但对其预训练和后训练方面

¹⁾ <https://tianchi.aliyun.com/competition/entrance/532183>

进行了大量优化,使其在某些方面超越了更大的模型。

ChatGLM3-6B:ChatGLM 系列新一代的开源模型,在保留前两代模型优秀特性的基础上,又新增更完整的功能支持,在语义、推理、知识等方面都具有良好性能。

Baichuan2-13B-chat:百川智能推出的新一代 13B 开源大语言模型,采用 2.6 万亿 token 的高质量语料训练,在中英文评测中均取得了领先的效果。

KnowLM-13B-IE:基于 llama1 底座模型微调得到的专业信息抽取模型框架,专注于知识抽取任务,旨在结合大模型和知识图谱,提升模型在知识抽取任务的表现。

4.2.2 评估指标

在评估模型实验效果时,本文主要采用精确率(P)、召回率(R)和 F1 值作为评估指标¹⁾。其中,精确率表示模型在所有被预测为正类的样本中,真正的正类样本所占的比例;召回率则衡量在所有实际为正类的样本中,有多少被正确预测为正类;F1 值是由精确率和召回率计算得到的,其计算式为 $F1 = (2 * P * R) / (P + R)$,能够更真实地反映模型的综合性能。

为评估模型在实际应用中的执行效率,采用推理时间、推理效率和显存消耗作为评价指标,全面地评估模型性能。其中,推理时间表示模型对全部测试集数据进行推理所需要的总时间,推理效率表示平均每条测试集数据的推理速度,显存消耗是指推理过程中模型所占用的显存空间。

4.2.3 实验参数设置

本文采用 LLAMA3-8B 模型作为数据标注的主干模型,OneKE 模型作为知识抽取的主干模型。在训练数据标注模型时,采用 LORA 微调的方法,使用 fp16 浮点数精度进行训练,学习率设置为 1×10^{-4} ,训练轮数为 10 轮。在训练知识抽取模型时,采用 LORA 微调的方法,训练模板为 llama2_zh,用 AdamW^[25]作为优化器,学习率设置为 5×10^{-5} ,训练轮数为 10 轮。所有实验均在单卡 NVIDIA RTX A6000-48 GB GPU 上进行。

4.3 实验结果

表 3 列出了通过本文所提框架进行零样本知识抽取后的整体性能,以及基线模型和其他对比实验的结果。表 3 中基线模型是指不对 OneKE 基础模型进行任何处理操作,直接将其用于测试集的推理。其中,* 表示数据标注和知识抽取均采用通用模型的实验结果;† 表示数据标注和知识抽取均采用专业模型的实验结果;◇表示数据标注采用通用模型,知识抽取采用专业模型。例如,Baichuan2-13B-chat + OneKE◇表示数据标注任务采用 Baichuan2-13B-chat 模型,知识抽取任务采用 OneKE 模型。值得注意的是,本文方法在测试集上的表现明显优于其他方法,与基线模型相比,该框架在两数据集上的 F1 值分别提高 7.13 个百分点和 8.59 个百分点,这进一步表明了所提框架在进行零样本知识抽取中的优越性。

为进一步分析所提框架中通用模型与专业模型协同合作的合理性,以复赛数据集为例,本节将进行相应的实验以进行

验证。首先,为了将无监督数据与测试集数据进行对齐,不可避免地需要进行数据标注。如果不进行数据标注而直接进行知识抽取,将无法获得可用于微调的数据,效果如基线模型所示,复赛测试集的 F1 值仅有 58.58%。

其次,为进一步验证数据标注任务和知识抽取任务分别采用通用模型和专业模型的有效性,设置了均使用通用模型的两项子任务进行实验。结果表明,使用通用模型处理这两项子任务 F1 最高仅为 58.77%,相较于本文所提模型降低了 8.4 个百分点,这主要是因为通用模型无法精准捕捉到特定领域的知识,并且在直接进行知识抽取时,通用模型无法对特定任务进行有效泛化,导致抽取结果的准确性降低。

此外,本节还设置了均采用专业模型的两项子任务进行实验。结果表明,使用专业模型 OneKE 和 KnowLM-13B-IE 进行知识抽取 F1 分别仅为 59.02%和 55.95%,主要是由于专业模型极大地限制了模型的知识推理能力,因此微调后的数据标注模型性能不佳。

表 3 各模型的零样本知识抽取对比结果

Table 3 Comparison results of zero-shot knowledge extraction for each model						
模型	初赛数据集			复赛数据集		
	精确率	召回率	F1 值	精确率	召回率	F1 值
基线模型	71.17	52.4	60.36	73.01	48.91	58.58
llama2-13B-chat*	47.35	37.75	42.01	45.30	35.17	39.60
llama3-8B*	60.12	53.95	56.87	57.91	59.65	58.77
ChatGLM3-6B*	56.02	50.49	53.11	54.62	48.61	51.44
Baichuan2-13B-chat*	62.72	61.39	62.05	55.35	61.31	58.18
ChatGLM3-6B+OneKE◇	60.96	64.80	62.82	59.49	64.03	61.68
Baichuan2-13B-chat+OneKE◇	64.27	62.97	63.61	60.52	64.90	62.63
OneKE†	60.52	64.90	62.63	57.65	62.14	59.02
KnowLM-13B-IE†	56.50	57.40	56.95	66.57	48.25	55.95
Ours	69.50	65.60	67.49	68.40	65.99	67.17

为进一步评估模型在实际应用中的执行效率,对各模型在推理时间、推理效率和显存消耗 3 个评价指标上进行了充分的实验。如表 4 所列,本文所提框架方法相比于 ChatGLM3-6B 和 Baichuan2-13B-chat 等模型,显存消耗更小。与基线模型等相比,本文方法的显存消耗略大一些。但总体而言,本文方法的资源消耗仍在可控范围之内。关于推理效率,本文方法与多个对比实验中的模型相比,推理效率更高,然而与基线模型等相比,推理效率略差。分析其原因主要在于,基于数据微调过后,模型的知识能力增强且知识变得更复杂,其生成能力需要从模型内部检索更多知识,导致推理效率有所降低。总体而言,综合考虑推理效率和显存消耗两个指标,本文方法在与其他模型差异不大的情况下,显著地提升了知识抽取性能。

上述实验及分析表明,采用通用模型与专业模型协同合作的方式来解决零样本知识抽取任务是可行的。值得注意的是,本文重点在于提出通用模型与专业模型相结合的框架,未来若出现更优秀的通用大模型和专业大模型时,进行替换即可。

¹⁾ 由于该测试集的标签未公开,因此只能将结果提交到评测网站以获取最终评测结果,且评测指标只能使用网站提供的评价标准。

表 4 各模型推理效率和显存消耗实验结果

Table 4 Experimental results in the reasoning efficiency and memory consumption with each model

模型	推理时间/秒	推理效率/(秒/条)	显存消耗/GB
基线模型	1 739	1.70	9.5
llama2-13B-chat	3 334	3.26	9.2
llama3-8B	2 060	2.01	6.9
ChatGLM3-6B	1 018	0.99	12.4
Baichuan2-13B-chat	1 607	1.57	17.1
OneKE	1 864	1.82	11.6
Ours	2 045	1.99	10.4

4.4 消融实验

为进一步表明所提框架中各模块之间的性能,对复赛数据集进行了相关的消融实验。从表 5 的消融实验结果可以看出,本框架中提出的 3 种方法在进行零样本知识抽取过程中均取得了一定的效果提升。

表 5 消融实验结果

Table 5 Ablation experiment results

(%)			
模型	精确率	召回率	F1 值
Ours	68.40	65.99	67.17
-数据标注	74.30 (+5.90)	49.50 (−16.49)	59.42 (−7.75)
-提示范式	66.33 (−2.07)	64.76 (−1.23)	65.54 (−1.63)
-属性增强	67.24 (−1.16)	65.36 (−0.63)	66.29 (−0.88)

当移除数据标注模块时,知识抽取的召回率和 F1 值分别降低 16.49 个百分点和 7.75 个百分点,这表明移除该模块后,模型没有相关数据的训练,会导致引入噪声或错误的标签,这些噪声和错误标签会降低模型的召回率和 F1 值。此外,在移除该模块后,模型的精确率反而得到提高,分析认为,这可能是模型更多地倾向于预测某些特定实体信息,而刻意

忽略其他实体信息的特征,导致特定类别的精确率得以提升,但并未抽取到更多的知识信息,同时这也使得模型召回率急剧下降。

当移除提示范式构造时,知识抽取的精确率、召回率和 F1 值指标均有不同程度的降低。通过分析认为,提示范式构造对于数据标注和知识抽取任务而言,有助于提供更明确的指令,帮助模型聚焦于相关信息,使得模型能够更好地理解任务。如果移除该模块,模型可能无法获得足够信息的操作指令,从而影响决策质量,因此精确率会下降。此外,提示范式构造能增强模型的泛化能力,使其在未知数据上表现更好,移除后,模型可能过拟合于训练数据,导致其在测试集上表现不佳,因此召回率会下降。

当移除属性增强模块时,知识抽取的精确率、召回率和 F1 值 3 项指标分别降低 1.16 个百分点、0.63 个百分点和 0.88 个百分点。这表明,通过大模型增强的属性解释提供了更为丰富的上下文描述信息和特征表示,尤其在处理复杂或模糊的任务时,由于缺少相应的属性解释支持,模型无法正确对任务本身做出清晰的判别。移除该模块后,模型对输入数据的理解能力不足,从而影响其抽取性能。此外,在实验过程中发现,如果将所有的属性解释信息都重新通过大模型生成,F1 值会下降至 65.26%。经过分析,主要原因是大模型可能产生属性解释幻觉问题,即生成错误的属性解释,这可能造成原本合理的属性解释被错误的解释所替代。因此综合考虑这一问题,本文最终仅对属性解释与属性名信息相同的信息进行大模型修正,以确保属性解释增强模块不会产生负面的影响。

4.5 案例分析

图 5 展示了本文所提框架与消融实验中输出结果的案例分析。其中,案例 1 对比了移除数据标注模块与本文方法的输出结果。



图 5 本文所提框架的案例分析

Fig. 5 Case studies of the proposed framework

从图中可以看出,移除数据标注模块后,模型无法有效识别“代表作品”和“出生地”等属性描述信息,导致抽取结果出现遗漏。这表明数据标注模块为模型提供了额外高质量的训练数据,使得模型在处理知识抽取任务时更具针对性,从而能更好地针对属性描述信息抽取相应的知识。案例 2 对比了移除提示范式构造与本文方法的输出结果。结果表明,移除提示范式构造后,模型将抽取的信息识别为“无”,主要原因在于当提示范式不清晰时,模型无法精准聚焦于问题本身,导致其出现误判的情况。案例 3 对比了移除属性增强模块与本文方法的输出结果。实验表明,通过大模型进行相应的属性解释增强后,模型能够对“所属作品”等模糊属性有更深入的解释,进而抽取更准确的知识。

结束语 本文提出了一个全新的零样本知识抽取框架,旨在利用大语言模型实现数据增强,避免人工标注数据所带来的成本消耗。该方法结合了通用大模型与专业大模型,利用微调通用大模型获得的数据标注模型,对爬取的相关文本进行推理获取实体和属性信息。随后,为推理得到的数据设置新的思维链提示,以构建相应的数据信息。基于这些数据,在专业大模型的基础上微调得到知识抽取模型,并通过不断迭代训练,优化模型的知识抽取性能。

然而,本文方法对于训练过程中使用的语料库质量具有一定依赖性,低质量的数据可能会影响知识抽取结果的可靠性,且大模型的决策过程缺乏透明性,使得用户难以理解模型的推理依据。因此,未来将考虑建立更具针对性且质量更高的多领域数据集,对不同行业的专业模型在各自领域内进行优化,并对跨领域知识之间的语义差异性进行对齐,避免不同语义之间的噪声影响,减少模型在跨领域任务中的偏差。此外,将领域特定的知识图谱与该方法相结合,利用知识图谱提供的结构化知识,提高大模型的输出可解释性,使得模型进行知识抽取的过程更加透明。

参 考 文 献

[1] LI B L, CHEN Y Z, YU S W. A Survey of Information Extraction [J]. Computer Engineering and Applications, 2003 (10): 1-5, 66.

[2] YU J J, WANG X, CHEN W L, et al. Self-training method for low resource relation extraction [J]. Journal of Software, 2025, 36(4): 1620-1636.

[3] WANG R Y, XIANG W, WANG B, et al. A survey of document-level event extraction [J]. Journal of Chinese Information Processing, 2023, 37(6): 1-14.

[4] ZHANG Q, SONG Y, GUO P, et al. CRMSP: A Semi-supervised Approach for Key Information Extraction with Class-Rebalancing and Merged Semantic Pseudo-Labeling [J]. arXiv: 2407.15873, 2024.

[5] QIN G, LIN N, SHEN M, et al. Global information enhancement and subgraph-level weakly contrastive learning for lightweight weakly supervised document-level event extraction [J]. Expert

Systems with Applications, 2024, 240: 122516.

[6] LYU Q, ZHANG H, SULEM E, et al. Zero-shot event extraction via transfer learning: Challenges and insights [C] // Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 322-332.

[7] SAINZ O, DE LACALLEO L, LABAKA G, et al. Label verbalization and entailment for effective zero-and few-shot relation extraction [C] // Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. (ACL 2021), 2021: 1199-1212.

[8] WANG C, LIU X, CHEN Z, et al. Zero-Shot Information Extraction as a Unified Text-to-Triple Translation [C] // Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 1225-1238.

[9] FU Y, LI X, SHANG C, et al. ZoIE: A Zero-Shot Open Information Extraction Model Based on Language Model [C] // 26th International Conference on Computer Supported Cooperative Work in Design (CSCWD 2023). IEEE, 2023: 784-789.

[10] YANG Q, HU Y, CAO R, et al. Zero-shot Key Information Extraction from Mixed-Style Tables: Pre-training on Wikipedia [C] // IEEE International Conference on Data Mining (ICDM 2021). IEEE, 2021: 1451-1456.

[11] MIN B, ROSS H, SULEM E, et al. Recent advances in natural language processing via large pre-trained language models: A survey [J]. ACM Computing Surveys, 2023, 56(2): 1-40.

[12] WANG X, ZHOU W, ZU C, et al. InstructIE: Multi-task instruction tuning for unified information extraction [J]. arXiv: 2304.08085, 2023.

[13] SAINZ O, GARCÍA-FERRERO I, AGERRI R, et al. Gollie: Annotation guidelines improve zero-shot information-extraction [J]. arXiv: 2310.03668, 2023.

[14] HU D, LIU B, ZHU X, et al. Zero-shot information extraction from radiological reports using ChatGPT [J]. International Journal of Medical Informatics, 2024, 183: 105321.

[15] KARTCHNER D, RAMALINGAM S, AL-HUSSAINI I, et al. Zero-Shot Information Extraction for Clinical Meta-Analysis using Large Language Models [C] // The 22nd Workshop on Biomedical Natural Language Processing and BioNLP Shared Tasks. ACL, 2023: 396-405.

[16] MANGRULKAR S, GUGGER S, DEBUT L, et al. Peft: State-of-the-art parameter-efficient fine-tuning methods [EB/OL]. <https://github.com/huggingface/peft>.

[17] GUI H, QIAO S, ZHANG J, et al. InstructIE: A Bilingual Instruction-based Information Extraction Dataset [J]. arXiv: 2305.11527, 2023.

[18] GUI H, YUAN L, YE H, et al. IEPile: Unearthing Large Scale Schema-Conditioned Information Extraction Corpus [C] // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. 2024: 127-146.

[19] ZHANG N, XU X, TAO L, et al. DeepKE: A Deep Learning

Based Knowledge Extraction Toolkit for Knowledge Base Population[C]// Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2022:98-108.

[20] TOUVRON H,MARTIN L,STONE K,et al. LLAMA 2: Open foundation and fine-tuned chat models[J]. arXiv:2307. 09288, 2023.

[21] DUBEY A,JAUHRI A,PANDEY A,et al. The LLAMA 3 herd of models[J]. arXiv:2407. 21783,2024.

[22] DU Z, QIAN Y, LIU X, et al. GLM: General Language Model Pretraining with Autoregressive Blank Infilling[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, 2022:320-335.

[23] YANG A, XIAO B, WANG B, et al. Bachman 2: Open large-scale language models[J]. arXiv:2309. 10305,2023.

[24] WANG P,ZHANG N,TIAN B, et al. Easyedit: An easy-to-use knowledge editing framework for large language models[J]. arXiv:2308. 07269,2023.

[25] LOSHCHILOV I,HUTTER F. Decoupled Weight Decay Regularization[C]// International Conference on Learning Representations, 2018.



PI Qiankun, born in 2000, postgraduate. His main research interests include knowledge graph, stance detection and large language model.



LU Jicang, born in 1985, Ph.D, associate professor. His main research interests include knowledge reasoning and social network analysis.

(责任编辑:柯颖)

评审结果公示 | 2025 年 CCF-绿盟科技“鲲鹏”科研基金

CCF-绿盟科技“鲲鹏”科研基金,是由 CCF 与绿盟科技于 2017 年共同发起,主要面向国内高校、科研机构的研究人员和团队,旨在以小微课题的方式支持科研人员的研究与创新,推动科研技术成果转化,促进外部科研机构优秀研发能力与企业产品价值的深度融合,构建互动合作与创新发展的生态圈。

第八期 CCF-绿盟科技“鲲鹏”科研基金项目于 2025 年 8 月正式启动征集以来,吸引了科研和学术界的广泛瞩目,共收到 80 余份来自国内知名高校和科研机构的申请。近日,CCF-绿盟科技“鲲鹏”科研基金项目组邀请了清华大学、中科院信工所等相关领域专家组成评委会,针对申报课题的研究基础、创新性、目标合理性等多方面进行了现场评审,最终共有 14 个项目通过评审,获得了 2025 年度 CCF-绿盟科技“鲲鹏”科研基金的资助。

以下是 2025 年度 CCF-绿盟科技“鲲鹏”科研基金评审结果(排名不分先后):

序号	姓名	学校	题目
1	杨超	西安电子科技大学	基于Carla的车路协同仿真安全技术研究
2	梁杰	北京航空航天大学	基于大语言模型的模糊测试智能体关键技术研究
3	高德宏	西北工业大学	基于大模型的代码审计与漏洞修复研究
4	张佳龙	西安交通大学	基于轻量化模型的攻击研判技术研究与验证
5	韩东岐	北京邮电大学	复杂场景下基于流量增强的可解释加密流量异常检测研究
6	胡晓艳	东南大学	基于多维特征深度融合的加密恶意流量检测关键技术研究
7	董理君	中国地质大学(武汉)	基于图关键要素推理增强的网络攻击检测技术研究
8	赵子鸣	浙江大学	开放网络环境下加密流量高速智能检测与软硬件协同系统研究
9	翟黎明	华中师范大学	面向边缘异构模型的鲁棒性水印技术研究
10	董枫	华中科技大学	基于智能体的自主事件调查技术研究
11	刘伟伟	南京理工大学	面向应用的加密流量高效检测与识别系统关键技术研究
12	王乐	广州大学	基于大模型的APT攻防靶标自动化构建研究
13	陈磊	中国传媒大学	面向真实网络环境的可信鉴深度伪检测关键技术研究
14	章学静	北京联合大学	基于智能体的资产攻击面管理关键技术研究

“鲲鹏展翅,非一羽之力;安全生态,非一日之功”。在未来的合作中,期待与各位老师共同深化学术研究,推动关键技术融合,共同构筑以企业为主导、市场为引领、产学研用深度融合的技术创新生态体系。